


Predicción de abandono estudiantil

Qué hace el código, paso a paso, explicado para quien no tiene conocimientos técnicos.



1 Resumen en una página

¿Qué es este código? Es un programa en Python que analiza una tabla con los datos de **100 estudiantes de tecnicaturas** (9 carreras) y busca patrones que diferencien a quienes **abandonaron** los estudios de quienes **continúan**. Para eso usa una técnica llamada **árbol de decisión**: una serie de preguntas de sí/no que, al contestarlas en orden, llevan a una predicción.

100

estudiantes de
9 tecnicaturas

54%

abandonaron
(54 de 100)

86%

abandono con una
sola materia aprobada

60%

acierto del árbol
(igual que adivinar)

¿Qué se puede decir con estos datos?

- **54 de los 100 estudiantes abandonaron** (54%).
- El dato que más pesa es la **cantidad de materias aprobadas en el primer cuatrimestre**: de los 14 estudiantes que aprobaron una sola materia, **12 abandonaron (86%)**.
- La asistencia, el promedio de notas y las materias desaprobadas aportan información secundaria.
- Datos como el género, si el estudiante trabaja o si realiza actividades extra casi no marcan diferencias (por ejemplo, 53% de abandono en mujeres frente a 55% en varones).

Conclusión importante sobre la confiabilidad

Al probar el árbol con 25 estudiantes que no había visto, **acertó en el 60%**. Parece aceptable, pero en esa misma muestra, **predecir "abandona" para todos también habría dado 60%** (15 de 25 abandonaron). Es decir, el árbol **no logra superar a una estrategia trivial**. Con 100 alumnos es una muestra chica. Sirve para **explorar y detectar una señal de alerta** (pocas materias aprobadas), pero **no debe usarse para decidir sobre una persona en particular**.

Las cifras de este informe se obtuvieron ejecutando el código tal cual está escrito sobre la tabla recibida (100 filas y 11 columnas).

2 Tres ideas previas para entender todo lo demás

2.1 Aprendizaje automático: que el programa descubra las reglas

Normalmente, una persona escribe las reglas ("si ocurre A, entonces B"). En el **aprendizaje automático** es al revés: se le muestran al programa muchos **casos del pasado con su desenlace conocido** (en este caso, estudiantes que ya abandonaron o continuaron) y el programa busca por sí mismo qué características se repiten en cada grupo. Un buen ejemplo en RRHH es el de una selección de personal: se revisan los currículums de quienes fueron contratados y funcionaron bien, para detectar qué rasgos tenían en común.

2.2 Árbol de decisión: un diagrama de preguntas

Un árbol de decisión es como el juego de las "veinte preguntas" o como el diagrama de flujo de un protocolo: se empieza por la primera pregunta (por ejemplo, "¿aprobó una materia o menos?"), y según la respuesta se pasa a otra pregunta o se llega a una conclusión. Tiene una gran ventaja para quien no es técnico: **se puede leer y explicar**, a diferencia de otros métodos que funcionan como una "caja negra".

2.3 Entrenar y probar: estudiar con ejercicios y rendir con otros nuevos

Si a un estudiante se le toma un examen con los mismos ejercicios que ya practicó, la nota no demuestra que haya aprendido. Con los modelos pasa igual. Por eso los datos se dividen en dos grupos: **75 alumnos para "entrenar"** (el árbol aprende sus reglas ahí) y **25 alumnos para "probar"** (se comprueba si las reglas funcionan con alumnos que nunca vio). La nota de ese examen es la que realmente importa.

3 Los datos de partida

La tabla (TablaPrediccionAbandono.csv) tiene una fila por estudiante y estas columnas:

Columna	Qué significa
edad	Edad del estudiante (entre 18 y 60 años en esta tabla).
genero	f (femenino) o m (masculino).
carrera	Tecnicatura que cursa (9 carreras distintas).
PromedioPrimerCuatrimestre	Promedio de notas del primer cuatrimestre.
CantMateriasAprobadas / Desaprobadas	Cuántas materias aprobó y cuántas desaprobó en el primer cuatrimestre.
AsistenciaPromedio(%)	Porcentaje promedio de asistencia a clases.
trabaja/NoTrabaja	Si el estudiante trabaja (Si / No).
DistanciaDomicilioAlInstituto(Kms)	Distancia entre su casa y el instituto.
ActividadesExtracurriculares(Estudio)	Si realiza otras actividades de estudio (Si / No).
EstadoFinal	Lo que se quiere predecir: "Abandonó" o "Continúa".

4 El código explicado paso a paso

El programa está dividido en bloques. Para cada uno se muestra, en gris, el fragmento de código y debajo qué hace en términos cotidianos.

PASO 0 Herramientas que se cargan al inicio

```
import pandas as pd
from sklearn.model_selection import train_test_split
from sklearn.tree import DecisionTreeClassifier, export_text
```

Es como abrir la caja de herramientas antes de empezar. **pandas** funciona como una planilla de Excel que se maneja con instrucciones. **scikit-learn** ("sklearn") es una biblioteca de herramientas de aprendizaje automático: de ahí se toman el divisor de datos (entrenamiento/prueba) y el árbol de decisión.

PASO 1 Leer la tabla

```
tabla = pd.read_csv("TablaPrediccionAbandono.csv", sep=";", decimal=",", encoding="latin1")
print("Cantidad de alumnos (filas) y de columnas:", tabla.shape)
```

Se abre el archivo con los datos. Los tres ajustes entre paréntesis le indican *cómo está escrito* el archivo: las columnas están separadas por **punto y coma**, los decimales usan **coma** (7,44 y no 7.44) y se usa una codificación (*latin1*) que permite leer bien las tildes y la letra ñ. El resultado impreso es **100 filas y 11 columnas**.

PASO 2 Preparar los datos

Los datos reales casi nunca llegan listos. Este bloque los "limpia" y los traduce para que el programa pueda trabajar con ellos.

a) Quedarse solo con casos claros. Se conservan únicamente los estudiantes cuyo estado final es "Abandonó" o "Continúa". Si hubiera filas vacías o con otro valor, se descartan. En esta tabla las 100 filas son válidas.

b) Corregir un error de escritura. Los 6 registros de Higiene y Seguridad en el Trabajo figuran como "TÉCNICATURA" (con tilde), mientras que el resto dice "TECNICATURA". Sin la corrección, el programa creería que son dos carreras distintas. La línea con *replace* unifica la escritura.

c) Definir qué se predice. El programa solo entiende números, así que se define: **1 = abandona** y **0 = continúa**. Los datos con los que se predice son todas las columnas excepto *EstadoFinal* (sería como darle la respuesta al examen).

d) **Convertir texto en números.** Las columnas con palabras se traducen así:

Columna	Traducción
genero	f = 0, m = 1
trabaja/NoTrabaja	No = 0, Si = 1
ActividadesExtracurriculares	No = 0, Si = 1

e) **Una columna por carrera.** No se puede escribir "Enfermería = 1, Radiología = 2..." porque el programa creería que Radiología "es más" que Enfermería. Lo que se hace es crear **una columna por cada carrera**, con un 1 si el alumno cursa esa carrera y un 0 si no (técnica llamada *get_dummies*). Por ejemplo, una estudiante de Enfermería tendría un 1 solo en la columna "carrera_ENFERMERÍA" y 0 en las otras ocho.

PASO 3 Entrenar el árbol

```
datos_entrenamiento, datos_prueba, resultado_entrenamiento, resultado_prueba = \
    train_test_split(datos, resultado, test_size=0.25, random_state=42)

arbol = DecisionTreeClassifier(max_depth=3, min_samples_leaf=5,
                               random_state=42, class_weight='balanced')
arbol.fit(datos_entrenamiento, resultado_entrenamiento)
```

Primero se hace la división explicada en el punto 2.3: **75% para entrenar** (75 alumnos) y **25% para probar** (25 alumnos). El número 42 es una "semilla": fija el sorteo para que, al repetir el análisis, la división sea siempre la misma y los resultados sean comparables.

Luego se configura el árbol con cuatro "reglas de juego":

Ajuste	Qué significa en palabras simples
max_depth=3	El árbol puede hacer como máximo 3 preguntas seguidas . Un árbol más profundo terminaría memorizando casos particulares en lugar de encontrar patrones generales.
min_samples_leaf=5	Cada conclusión final debe apoyarse en al menos 5 alumnos . Evita reglas basadas en uno o dos casos.
class_weight='balanced'	Si hubiera muchos más casos de un tipo, el programa los compensa para no ignorar al grupo minoritario.
random_state=42	Misma semilla para que el resultado sea reproducible.

Por último, *fit* es la orden de "aprender": el programa recorre los 75 casos de entrenamiento y elige, en cada paso, la pregunta que mejor separa a quienes abandonaron de quienes continúan.

PASO 4 ¿Qué tan bien funciona?

```
precision = arbol.score(datos_prueba, resultado_prueba)
porcentaje_abandonan = resultado.mean()
mas_comun = max(porcentaje_abandonan, 1 - porcentaje_abandonan)
```

Es el "examen" con los 25 alumnos reservados: el programa predice cada caso y se cuenta cuántas veces acertó ("precisión"). Para saber si ese número es bueno, se lo compara contra una **referencia básica**: qué porcentaje de aciertos se lograría sin ningún modelo, diciendo siempre la opción más frecuente. Si el modelo no supera esa referencia, no está aportando valor. **Resultado: 60% del árbol contra 54% de referencia** (y 60% si la referencia se calcula solo con los 25 alumnos de prueba; ver punto 6).

PASO 5 Variables más importantes

```
importancias = arbol.feature_importances_  
pares = sorted(zip(importancias, nombres), reverse=True)
```

Muestra cuánto "usó" el árbol cada dato para decidir, expresado en porcentaje (suman 100%). Solo se imprimen las que el árbol utilizó; las demás (edad, género, carrera, distancia, trabajo, etc.) no entraron en ninguna pregunta.

PASO 6 Porcentaje de abandono por grupo

```
tabla["abandono"] = resultado  
for columna in ["genero", "trabaja/NoTrabaja", ..., "carrera"]:  
    print(tabla.groupby(columna)["abandono"].mean() * 100)
```

Este bloque no usa el árbol. Es un cálculo directo y fácil de entender: se agrupan los estudiantes (por género, por si trabajan, por carrera, etc.) y se calcula qué porcentaje de cada grupo abandonó. Sirve para detectar en qué grupos el problema es mayor y orientar acciones.

5 Resultados obtenidos

5.1 El árbol que armó el programa

Así se lee el árbol: se empieza arriba, se responde cada pregunta con SÍ o NO y se sigue la flecha hasta llegar a una caja final. Los números indican cuántos de los 75 alumnos de entrenamiento terminaron en cada caja.




Figura 1. Árbol de decisión (calculado con los 75 alumnos de entrenamiento).

Lo más claro: los 11 alumnos con una sola materia aprobada (o ninguna) abandonaron todos. **Lo llamativo:** en la rama de la derecha, quienes desaprobaron *menos* materias abandonan más (63%) que quienes desaprobaron más (27%), y los de asistencia baja pero buen promedio casi todos continúan. Son resultados poco intuitivos que probablemente reflejan **casualidad por la muestra chica** más que un fenómeno real, y conviene no sacar conclusiones de esas ramas.

5.2 Qué datos pesaron más




Figura 2. Importancia de cada dato en el árbol. Los datos que no aparecen no se usaron.

Solo cuatro datos fueron utilizados. La cantidad de materias aprobadas explica casi la mitad de las decisiones del árbol.

5.3 Qué tan bien acertó

Medida	Resultado
Aciertos del árbol en los 25 alumnos de prueba	15 de 25 (60%)
Alumnos de prueba que abandonaron en realidad	15 de 25 (60%)
Aciertos si se dijera "abandona" para todos	15 de 25 (60%), igual que el árbol
Referencia que imprime el código (sobre los 100 alumnos)	54%
De los 15 que abandonaron, el árbol detectó	11 (se le escaparon 4)
De los 10 que continuaron, el árbol identificó correctamente	4 (marcó como "abandona" a 6 que siguieron)

5.4 Porcentaje de abandono por grupo

Según materias aprobadas en el primer cuatrimestre (n = cantidad de alumnos del grupo):




Figura 3. El único grupo que se destaca claramente es el de una sola materia aprobada (86%).

Según carrera:




Figura 4. Abandono por carrera. La línea punteada marca el promedio general (54%). Los grupos tienen entre 6 y 15 alumnos, por lo que las diferencias deben tomarse con mucha cautela.

Grupo	% de abandono	Comentario
Mujeres / Varones	53,1% / 54,9%	Sin diferencia relevante.
No trabaja / Trabaja	56,1% / 51,2%	Diferencia pequeña.
Sin actividades extra / Con actividades extra	51,1% / 56,6%	Diferencia pequeña, y en sentido contrario a lo esperable.

Cómo interpretar estos resultados con prudencia

- **La muestra es muy chica.** En el grupo de prueba hay 25 personas: cada alumno equivale a 4 puntos porcentuales. Un par de casos distintos cambiarían el resultado. Los grupos por carrera tienen entre 6 y 15 personas.
- **El árbol no supera la referencia trivial.** En el grupo de prueba, 15 de 25 abandonaron, así que decir "todos abandonan" daría también 60%. Además, el código compara contra el 54% de los 100 alumnos, una referencia algo distinta a la del grupo de prueba. Es un detalle que conviene tener presente al leer la comparación.
- **Algunas reglas no tienen sentido práctico** (por ejemplo, que desaprobado más materias se asocie a abandonar menos). Suelen ser señales de que el árbol se ajustó a coincidencias de la muestra.
- **Correlación no es causa.** Que quienes aprueban pocas materias abandonen más no significa que aprobar poco cause el abandono: ambas cosas pueden deberse a otros factores (carga laboral, problemas personales, orientación equivocada) que la tabla no registra.
- **Importante en el uso:** estas herramientas pueden orientar políticas de apoyo, pero no deberían usarse para excluir, calificar o decidir sobre una persona. Siempre debe intervenir el criterio humano.

Recomendaciones para la institución

Las siguientes propuestas se apoyan en lo que muestran los datos analizados, no solo en el árbol: se incluyen también comparaciones directas entre grupos que complementan el modelo. Como la muestra es pequeña (100 estudiantes), conviene leerlas como **hipótesis razonables para probar** y no como verdades confirmadas. Están ordenadas por prioridad.



Una advertencia antes de empezar

La señal más fuerte (una sola materia aprobada) alcanza a **12 de los 54 estudiantes que abandonaron (22%)**. Los otros 42 abandonaron con 2 o más materias aprobadas. Por eso, una alerta basada solo en el rendimiento académico es necesaria pero **insuficiente**.

1

PRIORIDAD ALTA

Crear un protocolo de alerta temprana al cierre del primer cuatrimestre

En qué se basa: De los 14 estudiantes que aprobaron una sola materia, 12 abandonaron (86%). Es la regla más clara y la única que no depende de modelos complejos.

Qué hacer: Contactar a cada estudiante en esa situación dentro de las primeras semanas del segundo cuatrimestre: entrevista con un tutor o preceptor, revisión de las causas y un plan de cursada acorde (por ejemplo, menos materias simultáneas, apoyo en las que desaprobó). Si es posible, anticipar la alerta a mitad de cuatrimestre usando los parciales.

2

PRIORIDAD ALTA

No asumir que el abandono es solo un problema de rendimiento

En qué se basa: Entre quienes aprobaron 6 o más materias, abandonó el 65% (13 de 20), frente al 44% de quienes aprobaron entre 2 y 5. Con promedio de 8 o más abandonó el 58%, y con promedio menor a 6, el 52%. Es decir, **las buenas notas no protegen del abandono**.

Qué hacer: Complementar la alerta académica con una consulta breve a todos los estudiantes al inicio y a mitad de cursada (situación laboral, tiempo disponible, responsabilidades familiares, expectativas de la carrera). Aplicar entrevistas de salida a quienes dejan para conocer sus motivos.

Referencia visual para la recomendación 3: el porcentaje de abandono sube con la edad.




Figura 5. Abandono por tramo de edad (la línea punteada marca el promedio general de 54%). Es una tendencia descriptiva: el árbol no usó la edad y, con tan pocos casos, la diferencia no es estadísticamente concluyente.

3

PRIORIDAD ALTA

Diseñar apoyos específicos para estudiantes adultos

En qué se basa: Abandonó el 29% de los estudiantes de 18 a 24 años (5 de 17), contra el 63% de los de 45 a 60 (25 de 40). Casi 3 de cada 5 estudiantes de la tabla tienen 35 años o más, por lo que este grupo pesa mucho en el total.

Qué hacer: Primero, preguntarles qué obstáculos enfrentan (horarios, tiempo, conciliación con trabajo o familia, uso de tecnología). Luego probar opciones de flexibilidad: horarios alternativos, materiales y clases grabadas, tutorías de acompañamiento y contacto frecuente.

4

PRIORIDAD MEDIA

Investigar en profundidad las carreras con mayor abandono

En qué se basa: Ciencia de Datos e IA (75%, 12 alumnos), Diseño Industrial (67%, 12) y Higiene y Seguridad (67%, 6) lideran el abandono. En el otro extremo están Enfermería (36%) y Radiología (38%). Los grupos son chicos, por lo que las diferencias son orientativas.

Qué hacer: Antes de intervenir, hacer entrevistas o grupos de conversación con estudiantes y docentes de esas carreras para entender qué ocurre en el primer cuatrimestre (carga, dificultad de las materias iniciales, expectativas). Conocer también qué prácticas de acompañamiento tienen las carreras con menor abandono para evaluar si pueden replicarse.

5

PRIORIDAD MEDIA**Evitar medidas basadas en género, trabajo, distancia o actividades extra**

En qué se basa: Los datos no muestran diferencias relevantes: abandono de 53% en mujeres y 55% en varones; 56% en quienes no trabajan y 51% en quienes trabajan; entre 50% y 56% según la distancia al instituto. El árbol tampoco utilizó estas variables.

Qué hacer: Concentrar los recursos en las señales que sí aparecen (rendimiento inicial, edad, carrera) y no en programas dirigidos a esos perfiles. Revisar la conclusión cuando se tengan más datos.

6

PRIORIDAD BASE**Mejorar la recolección de datos**

En qué se basa: El modelo no logra superar una predicción trivial, y buena parte de la causa probable del abandono no está en la tabla.

Qué hacer: Registrar de forma sistemática: fecha y motivo de la baja, resultados por cuatrimestre (no solo el primero), turno, situación laboral detallada, becas o apoyos recibidos, y contactos realizados por tutores. Unificar la escritura de las carreras para evitar errores como el de "TÉCNICATURA". Reunir idealmente varios cientos de estudiantes antes de volver a modelar.

7

PRIORIDAD BASE**Probar las acciones con un piloto y medir su efecto**

En qué se basa: Sin medición, no es posible saber si una intervención reduce realmente el abandono o si los estudiantes que reciben apoyo ya iban a continuar de todos modos.

Qué hacer: Aplicar cada acción primero a un grupo piloto y comparar con otro grupo similar que no la reciba. Revisar los resultados al finalizar cada cuatrimestre y ajustar.

8

PRIORIDAD BASE**Usar el modelo con criterio humano y de forma responsable**

En qué se basa: El árbol actual acierta lo mismo que una predicción trivial y se apoya en una muestra pequeña.

Qué hacer: Usarlo como apoyo para orientar el acompañamiento, nunca para excluir, calificar o decidir sobre una persona. Informar a los equipos sobre sus límites, volver a entrenarlo cada año con datos nuevos y verificar que no perjudique a ningún grupo (por ejemplo, por edad o género).

Hoja de ruta sugerida

Plazo	Acciones
Primeros 3 meses	Protocolo de alerta temprana (1). Registro de motivo y fecha de baja (6). Entrevistas en Ciencia de Datos e IA, Diseño Industrial e Higiene y Seguridad (4).
De 3 a 6 meses	Consulta breve de riesgo a todos los estudiantes (2). Piloto de apoyos para estudiantes adultos (3). Primeras mediciones comparando grupo piloto y grupo de control (7).
De 6 a 12 meses	Repetir el análisis con la nueva cohorte y con más datos (6 y 8). Mantener lo que funcione, ajustar o descartar el resto.

Indicadores para dar seguimiento

Indicador	Qué permite saber
Tasa de abandono por cohorte y por carrera	Si el problema mejora con el tiempo y dónde persiste.
% de estudiantes en alerta contactados dentro de las 3 semanas	Si el protocolo se cumple realmente.
Abandono entre estudiantes en alerta, con y sin acompañamiento	Si el apoyo ofrecido marca una diferencia.
Motivos de baja más frecuentes	Qué causas atacar primero, más allá del rendimiento.

8

Glosario

Término	Significado simple
Algoritmo / modelo	Conjunto de reglas que un programa usa para llegar a una predicción.
Árbol de decisión	Modelo que predice mediante una cadena de preguntas de sí/no.
Entrenar	Mostrarle al programa casos pasados para que aprenda las reglas.
Datos de prueba	Casos que el programa nunca vio, usados para evaluarlo.
Precisión	Porcentaje de casos en que la predicción fue correcta.
Variable	Cada columna de la tabla (edad, carrera, asistencia, etc.).
Importancia de una variable	Cuánto usó el árbol esa columna para decidir.
Referencia (línea base)	Resultado que se lograría sin modelo, útil para saber si el modelo aporta algo.
Semilla (random_state)	Número que fija un sorteo para poder repetir exactamente el mismo resultado.
Sobreajuste	Cuando un modelo memoriza los casos de entrenamiento y falla con casos nuevos.
pandas / scikit-learn	Bibliotecas de Python: la primera maneja tablas, la segunda ofrece herramientas de aprendizaje automático.